

06: Análise de Componentes Principais e Análise Fatorial

* Conteúdo	Laboratório
📅 Data da Aula	set. 8
📄 Disciplina	📊 <u>Análise Multivariada</u>

O objetivo do PCA é introduzir/preparar os dados para a análise fatorial.

- Número de variáveis
- Trata-las
 - Variáveis altamente correlacionadas: resultado/análise final prejudicados.

Reduzir/tratar as variáveis relacionadas.

Realiza uma combinação linear das variáveis de forma que os fatores resultantes sejam não-relacionados.

1. Padronização dos dados: com o objetivo de chegar em média 0 e desvio padrão 1
2. Calcular a matriz de correlação ou covariância
3. Encontrar os autovalores e autovetores dessa matriz
 - **Autovalores:** indica quanta **variabilidade** cada componente explica.
 - **Autovetores:** indica a direção de cada componente no espaço
4. Seleção dos componentes principais
5. Transformação de dados em um novo espaço dimensional

`colMeans(dados[, 2:ncol(dados)])` #calcular a média de coluna por coluna-

```
# EXEMPLO 1 #
```

```

#Carregando os dados (arquivo dados_pca-exemplo1.csv)

# 1-Normalização dos dados -----
-----
dados <- dados_pca.exemplo
head(dados) #Observe que a primeira coluna é só identificação da empresa
colMeans(dados[, 2:ncol(dados)]) #calcular a média de coluna por coluna

# Padronização dos dados
dados_norm <- scale(dados[, 2:ncol(dados)]) # Da coluna 2 até a última
head(dados_norm)

# Conferência da normalização
colMeans(dados_norm) #Média é 0
sd(dados_norm[, 3]) #Desvio-padrão é 1

# 2-Matriz de correlação -----
-----
mat_cor <- cor(dados_norm)
print(mat_cor, digits = 2) # Alta correlação: Clientes x Vendas, Tamanho x NFuncionários

# Gráfico de correlação
if(!require(corrplot)) install.packages("corrplot")
library(corrplot)
corrplot(mat_cor, method = "circle")
corrplot(mat_cor, method = "number")

# 3-Autovalores -----
-----
ev <- eigen(mat_cor)
print(ev$values, digits = 2) # Os autovalores > 1 indicam a quantidade de PCAs a serem definidos

```

```

ev$values/sum(ev$values) # Explica quanto da variabilidade
dos autovalores
  # Mínimo de escolha: 80%

# 5-Calculando PCA -----
-----

resultado <- princomp(dados_norm)

summary(resultado)

#Visualização dos PCA
if(!require(factoextra)) install.packages("factoextra")
library(factoextra)
fviz_eig(resultado, addlabels = TRUE)

# 5-Definindo o numero de componentes principais -----
-----

plot(resultado)
abline(h = 1, col = "red", lwd = 2) #insere a linha horizon
tal)

biplot(resultado, scale=0)
fviz_pca_var(resultado, col.var = "cos2",
              gradient.cols = c("black", "orange", "green"),
              repel = TRUE)
resultado$scores

```

Análise Fatorial

1. Cálculo da **Matriz de Correlação**
2. **Teste de esfericidade de Bartlett:** define se a matriz de correlação é significativa

- H0: A matriz de correlação é uma matriz identidade (não há correlação significativa entre as variáveis)
 - Se $p > 0,05$, rejeita-se H0, não havendo correlações significativas.

3. Cálculo do **KMO**: mede a adequação dos dados para Análise Fatorial

- $> 0,6$: Ideal
 - $> 0,80$: Adequado
 - $0,70 < KMO < 0,80$: Aceitável, mas deve-se ter cautela
 - $0,60 < KMO < 0,70 \rightarrow$ Questionável
 - $KMO < 0,50 \rightarrow$ Não é adequado para Análise Fatorial

#CORRELACAO

A - Bando de dados TREES

```
dados <- trees
```

```
View(dados)
```

```
head(dados)
```

#Renomeando as colunas dos dados TREES

```
colnames(dados) <- c("Circunferencia", "Altura", "Volume")
```

```
View(dados)
```

1-Normalização dos dados -----

```
colMeans(dados) #calcular a média de coluna por coluna
```

```
dados_norm <- scale(dados)
```

```
head(dados_norm)
```

```
colMeans(dados_norm) #Média é 0
```

```
sd(dados_norm[,1]) #Desvio-padrão é 1
```

2-Calcula a matriz de correlação -----

```
matcor <- cor(dados_norm)
```

```
print(matcor, digits =2)
```

#Analisando a correlacao por grafico

```

if(!require(corrplot)) install.packages("corrplot")
library(corrplot)
corrplot(matcor, method = "circle")
#Visualizando por numero
corrplot(matcor, method = "number")

# 3-Teste de Bartlett -----
-----
# H0: Não há correlação
if(!require(psych)) install.packages("psych")
library(psych)
bartlett_result <- cortest.bartlett(dados_norm)
print(bartlett_result)

# 4- Teste KMO -----
-----
kmo_result <- KMO(dados_norm)
print(kmo_result) #Medida de adequação da amostra (MSA)
# Exclui o que possui menor KMO

```

```

#PASSOS DA ANALISE FATORIAL
# A - Bando de dados CREME DENTAL (Arquivo Excel)
#Importar os dados CREME DENTAL da pasta

dados <- exemplo1_creme_dental

# 1-Normalização dos dados -----
-----

colMeans(dados) #calcular a média de coluna por coluna

dados_norm <- scale(dados)
head(dados_norm)

```

```

colMeans(dados_norm) #Média é 0
sd(dados_norm[,1]) #Desvio-padrão é 1

# 2-Calcula a matriz de correlação -----
-----
matcor <- cor(dados_norm)
print(matcor, digits =2)

#Analisando a correlacao por grafico
if(!require(corrplot)) install.packages("corrplot")
library(corrplot)
corrplot(matcor, method = "circle")
#Visualizando por numero
corrplot(matcor, method = "number")

# 3-Teste de Bartlett -----
-----
if(!require(psych)) install.packages("psych")
library(psych)
bartlett_result <- cortest.bartlett(dados_norm)
print(bartlett_result)

# 4- Teste KMO -----
-----
kmo_result <- KMO(dados_norm)
print(kmo_result) #Medida de adequação da amostra (MSA)

# DETERMINACAO DO NUMERO DE FATORES - ANALISE DOS COMPONENTES PRINCIPAIS -----
#Passo 1: Calculo dos autovalores
ev <- eigen(matcor)
print(ev$values, digits = 2)
print(ev$values[ev$values >= 1]) #Visualiza quantos são maiores que 1

#Análise dos Componentes Principais
PC <- princomp(dados, cor=TRUE) #Análise dos Componentes Principais

```

```

ncipais
print(PC, digits = 2)
summary(PC)
screeplot(PC)
plot(PC,type="lines")
abline(h = 1, col = "red", lwd = 2) #insere a linha horizon
tal)

#Ao determinar nfatores=2, representam 82,49% das vari?ncia
s das 6 variaveis
#Calculo da matriz de fatores - Nao rotacionada
n <- nrow(dados_norm)

PCAdente<-principal(dados_norm, nfactors=2,
                    n.obs=n,rotate="none", scores=TRUE)
PCAdente

#Calculo da matriz de fatores - Rotacionada - VARIMAX
PCAdenteMAX<-principal(dados, nfactors=2,
                      n.obs=n,rotate="varimax", scores=TRUE)
PCAdenteMAX
PCAdenteMAX$loadings #Exibe a contribui??o de cada vari?ve
l
print(PCAdenteMAX$loadings, cutoff = 0.75) #Exibe com cort
e de 0.75

#Definicao dos fatores
#Fator 1 (V1, V3, V5): Eficiencia
#Fator 2 (v2, v4, v6): Qualidade

escores <- PCAdenteMAX$escores
escores

dados1 <- data.frame(escores)
colnames(dados1) <- c("Eficiencia", "Qualidade")
View((dados1))

```

```
#Exportando os dados (criando um arquivo de dados)  
write.csv(dados1, file = "creme_dental.csv")
```