

08: Atividade de Análise Fatorial

* Conteúdo	Laboratório
📅 Data da Aula	set. 15
📖 Disciplina	🕒 <u>Análise</u> <u>Multivariada</u>

#PASSOS DA ANALISE FATORIAL

Agrupar variáveis altamente relacionadas

1-Normalização dos dados -----

```
dados <- satisfacao_clientes  
colMeans(dados) #calcular a média de coluna por coluna, es  
tão dentro do mesmo intervalo?
```

```
dados_norm <- scale(dados) # OPC: padronização dos dados, m  
édia 0, desvio 1  
head(dados_norm)
```

```
colMeans(dados_norm) #Média é 0  
sd(dados_norm[,1]) #Desvio-padrão é 1
```

2-Calcula a matriz de correlação -----

```
matcor <- cor(dados_norm)  
print(matcor, digits =2)
```

```
#Analisando a correlacao por grafico  
if(!require(corrplot)) install.packages("corrplot")
```

```

library(corrplot)

corrplot(matcor, method = "circle") # visualização dos três
possíveis fatores
#Visualizando por numero
corrplot(matcor, method = "number") # existe correlação


# 3-Teste de Bartlett -----
-----
if(!require(psych)) install.packages("psych")
library(psych)

bartlett_result <- cortest.bartlett(dados_norm)
# H0: Não há correlação
print(bartlett_result)
# olhar o valor de p.value (rejeita ou aceita)
# a força de H0 é fraco = há correlação


# 4- Teste KMO -----
-----
kmo_result <- KMO(dados_norm)
print(kmo_result) #Medida de adequação da amostra (MSA)
                  # Acima de 0,6 = ok
                  # Aceita-se um mínimo de 60%


# Bartlett mostra que há correlação e o KMO geral (medida d
e adequação) deu 0.74
# e todos os KMOs individuais foram maiores que 0.6.

```

```
# 5 - DETERMINACAO DO NUMERO DE FATORES - ANALISE DOS COMPO  
NENTES PRIN -----
```

```
#Passo 1: Calculo dos autovalores
```

```
ev <- eigen(matcor)
```

```
print(ev$values, digits = 2) # Quantidade de valores > 1 =  
número de fatores
```

```
print(ev$values[ev$values >= 1]) #OPC: Visualiza quantos s  
ão maiores que 1
```

```
#Passo 2: Analise dos Componentes Principais
```

```
PC <- princomp(dados, cor=TRUE) # Analise dos Componentes Pr  
incipais
```

```
print(PC, digits = 2)
```

```
summary(PC) # Verificar a variabilidade acumulada dos compo  
nentes agrupados
```

```
      # Cumulative Proportion
```

```
# Com 3 fatores, explica-se 83% da variabilidade
```

```
# Aceita-se um mínimo de 60%
```

```
screeplot(PC)
```

```
abline(h = 1, col = "red", lwd = 2) #insere a linha horizon  
tal)
```

```
# OPC: Passo 3: Calculo da matriz de fatores - Nao rotacion  
ada
```

```
n <- nrow(dados_norm) # numero de linhas dos dados
```

```
PCA <- principal(dados_norm, nfactors=3,
```

```
n.obs=n,rotate="none", scores=TRUE)
```

PCA

```
#Passo 4: Calculo da matriz de fatores - Rotacionada - VARI  
MAX
```

```
PCAMAX<-principal(dados, nfactors=3,  
n.obs=n,rotate="varimax", scores=TRUE)
```

PCAMAX

```
# Avalia-se o H2 (comunalidades), se todos são maiores que  
0.5
```

```
# root mean (no finalzinho) tem que ser menor do que 0.05
```

```
PCA$loadings #Exibe a contribui??o de cada vari?vel
```

```
# Acessar a tabela dos slides, quantas observações e tamanh  
o do corte
```

```
print(PCA$loadings, cutoff = 0.40) # OPC: Exibe com corte  
de 0.40
```

```
print(PCAMAX$loadings, cutoff = 0.40) #Exibe com corte de  
0.40
```

```
# Não pode haver uma mesma linha com valores em duas coluna  
s.
```

```
#6 - Definicao dos fatores ----
```

```
#Fator 3 : Valor e Preço
```

```
#Fator 2 : Qualidade do Produto
```

```
#Fator 1 : Serviço e Logística
```

```
escores <- PCAMAX$scores
```

```
escores
```

```
dados1 <- data.frame(escores)
```

```
View((dados1))
```

```
boxplot(dados1)
```

```
sample(1:5, 5)
```

```
treinamento <- c(2,3,4,5,6,7,8,9,10,11)
vendas <- c(18,20,23,25,27,30,32,35,36,40)
dados <- data.frame(treinamento, vendas)
```

```
# Identificando a variável dependente -----
```

```
-----
correlacao <- cor(dados)
print(correlacao, digits = 3)
View(correlacao)
```

```
# Usando o R para estimar os parâmetros -----
```

```
-----
modelo <- lm(dados, formula= vendas ~ treinamento)
modelo$coefficients # equação da reta, vendas = 13.0788 +
2.3878*treinamento
print(modelo$coefficients, digits = 4)
# a cada hora a mais de treinamento, a tendência é aumentar
em 2.38 as vendas
```

```
# Avaliação da precisão da previsão -----
```

```
-----
summary(modelo)
# R, R²: aceitar a partir de 0.6
# p-value: deve estar próximo de 0
# Pr(>|t|), H0: alfa e beta iguais a 0

# Gráfico dos resíduos
plot(modelo, which = c(1:3), pch=20)
```

```
shapiro.test(modelo$residuals)
# H0: Dados são normais
if(!require(car)) installed.packages("car")
library(car)
durbinWatsonTest(modelo)

plot(dados$treinamento, dados$vendas)
abline(modelo, col= "purple", lwd = 2)
```