

4. Análise de Componentes Principais (PCA)

4. Análise de Componentes Principais (PCA)

O problema que o PCA resolve:

Quando temos muitas variáveis, é difícil analisar, visualizar e interpretar.

- Algumas variáveis podem estar correlacionadas (ex.: altura e peso).
- Muitas podem conter informações redundantes.

O PCA serve para reduzir a dimensionalidade (diminuir o número de variáveis) sem perder muita informação.

4. Análise de Componentes Principais (PCA)

A ideia central do PCA

O PCA procura **novas variáveis** (chamadas **componentes principais**) que são:

- combinações lineares das variáveis originais,
Se Y_{ij} é um componente principal, então ele é uma combinação linear de n variáveis

$$Y_{ij} = a_1x_{i1} + a_2x_{i2} + a_3x_{i3} + a_nx_{in}$$

$a_1, a_2, a_3, \dots, a_n$ são pesos para cada variável

- não correlacionadas entre si,
- ordenadas de modo que o primeiro componente explica a maior parte da variação dos dados, o segundo explica a maior parte da variação restante, e assim por diante.

4. Análise de Componentes Principais (PCA)

Passo a passo do PCA

1. Padronização dos dados, caso as variáveis estejam em escalas diferentes (média 0 e desvio padrão 1);
2. Calcular a matriz de correlação ou covariância das variáveis;
3. Encontrar autovalores e autovetores dessa matriz:
 - Autovalores – indica quanta variabilidade cada componente explica;
 - Autovetores – indica a direção de cada componente no espaço;
4. Seleção dos componentes principais;
5. Transformação de dados em um novo espaço dimensional

4. Análise de Componentes Principais (PCA)

Determinando o número de componentes

Quando a intenção é a redução de dimensionalidade do problema, é necessário estabelecer critérios para a determinação do número de componentes:

- Critério de Kaiser.
 1. Manter as componentes principais correspondentes aos **autovalores maiores que a média dos autovalores**, se a análise for a **matriz covariância**
 2. Manter as componentes principais correspondentes aos **autovalores maiores que 1**, se a **matriz de correlação** for usada.
- Reter o número de componentes principais que acumulem pelo menos certa **porcentagem da variabilidade total dos dados**, por exemplo, 80%.
- Reter o número de componentes principais que acumulem pelo menos uma certa **porcentagem da variabilidade de cada uma das variáveis originais**, por exemplo, 50%.