

Preparação dos dados

1. **Análise dos dados perdidos**
2. *Outliers*

3.1 Análise dos Dados perdidos

3.1 Dados perdidos

Dados perdidos, são valores sobre uma ou mais variáveis que não estão disponíveis para análise.

Impacto dos dados perdidos:

- Redução do tamanho da amostra disponível para análise.
- Tornar o processo não-aleatório, pois pode provocar a perda de certos dados e esses conduzirem a resultados errôneos. Ou ainda, a uma análise tendenciosa.

Observação:

A preocupação com dados perdidos é semelhante à necessidade de compreender as causas de ausência de resposta no processo de coleta de dados.

3.1 Análise dos Dados perdidos

Etapas para tratar os dados perdidos

Dados perdidos, são valores sobre uma ou mais variáveis que não estão disponíveis para análise.

1. Passo 1: *Determinar o tipo de dados perdidos*

Dados perdidos ignoráveis:

Por exemplo: no exame de resolução de reclamações de clientes. Pode exigir ao cliente que, antes de registrar uma reclamação, respondam uma certa pergunta. Para os respondentes que não estão reclamando, não há necessidade de responder, e assim criam-se dados perdidos.

Dados perdidos NÃO-ignoráveis:

Um exemplo é a recusa em responder certas questões. O pesquisador deveria antecipar este problema e corrigi-lo no planejamento da pesquisa e no estágio da coleta de dados.

3.1 Análise dos Dados perdidos

2. Passo 2: *Determinar a extensão de dados perdidos*

Qual quantia de dados perdidos é excessiva?:

Dados perdidos **abaixo de 10%** para um caso ou observação individual podem ser ignorados, exceto quando os dados perdidos acontecem de maneira não-aleatória.

Ações Corretivas:

- Eliminar Variável ou Observação
- Verificar a Aleatoriedade
- Substituição dos valores perdidos por:
 - média, mediana
 - utiliza a regressão para calcular o valor com base nas outras variáveis no conjunto de dados

Preparando os dados

1. *Análise dos dados perdidos*
2. ***Outliers***

3.2 Outliers

São observações atípicas, são observações com uma combinação única de características identificáveis como sendo notavelmente diferentes das outras observações.

- Observações atípicas podem ter um efeito sensível sobre qualquer tipo de análise.

Por exemplo: considere uma amostra de 20 indivíduos na qual queremos determinar a renda média familiar. Em nossa amostra reunimos respostas que variam entre R\$20.000,00 e R\$100.000,00 ao ano, de modo que a média é de R\$45.000,00 por ano. Mas considere que a 21ª pessoa tem uma renda de R\$1 milhão ao ano. Se incluirmos esse valor na análise, a renda média aumenta para mais de R\$90.000,00. Naturalmente que a observação atípica é um caso válido, mas qual é a melhor estimativa de renda familiar média: R\$45.000,00 ou R\$90.000,00? O pesquisador deve avaliar se o valor marginal deve ser mantido ou eliminado, devido à sua influência indevida sobre os resultados.

3.2 Outliers

- ✓ A observação atípica deve ser vista sob a óptica do quão representativa ela é na população.

Novamente, usando nosso exemplo de renda familiar, qual é a representatividade do milionário no segmento mais abastado?

Se o pesquisador percebe que é um segmento pequeno mas viável na população, então talvez o valor deva ser mantido.

Se, porém, esse milionário é o único na população inteira e verdadeiramente representa um valor extremo acima de todos, então o mesmo deve ser eliminado.