

6. Regressão Linear e Múltipla

Um Exemplo de Regressão Simples

Regressão simples


$$\hat{Y} = \alpha + \beta X$$

Variável dependente (métrica)

Variável Independente (métrica)

- α e β são estimados através do **Método dos Mínimos Quadrados Ordinários**. O objetivo do método é obter uma reta que minimiza as distâncias entre os valores estimados e os valores observados.
- α representa o intercepto da reta, ou seja, onde ela cruza o eixo Y. O valor de $\hat{Y}$ quando $X = 0$.
- β representa o efeito da variável explicativa (X) sobre a variável resposta ($\hat{Y}$).

Método dos Mínimos Quadrados Ordinários - MQO



Função de regressão amostral:

$$Y_i = \hat{\alpha} + \hat{\beta}X_i + \hat{e}_i$$

Y previsto pelo ajuste:

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}X_i$$

Resíduo, valor não previsto pelo ajuste:

$$\hat{e}_i = Y_i - \hat{Y}_i$$

Método dos Mínimos Quadrados Ordinários - MQO

Estimadores de Mínimos Quadrados Ordinários

Y previsto pelo ajuste:

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}X_i$$

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

$$\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$$

$$x_i = X_i - \bar{X}$$

$$y_i = Y_i - \bar{Y}$$

$\bar{X}$ é a média das observações em x_i

$\bar{Y}$ é a média das observações em y_i

Avaliação do modelo

Coeficiente de determinação (R^2):

O coeficiente de determinação (R^2) é uma medida de qualidade do modelo em relação à sua habilidade de estimar corretamente os valores da variável resposta y .

$$R^2 = \frac{SQReg}{STQ} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$



$$\text{Coeficiente de determinação } (R^2) = \frac{\text{Soma de quadrados de regressão}}{\text{Soma total de quadrados}}$$

$\bar{y}$ = média de todas as observações

y_i = valor da observação individual i

$\hat{y}_i$ = valor previsto da observação i

Avaliação do modelo

Análise do modelo

Neste momento vamos realizar as seguintes avaliações:

1. O **coeficiente de regressão (R^2)**: analisando o quanto a equação explica o modelo. O valor deve estar próximo de 1;
2. O **R^2 ajustado**: R^2 ajustado é uma medida corrigida de adequação (precisão do modelo) para modelos lineares. Ele identifica a porcentagem de variação no campo de destino que é explicada pela entrada ou entradas. O valor deve estar próximo de 1;
3. O **Teste t** para os estimadores: $H_0: \alpha$ ou β iguais a zero. Rejeita-se H_0 se $p\text{-value} < 0.05$ e conclui-se que o parâmetro não é igual a zero na equação.
4. O **Teste F**: As hipóteses para o teste F da significância global são as seguintes:
 H_0 : O ajuste do modelo somente com o intercepto e seu modelo são iguais.
 H_1 : O ajuste do modelo somente com intercepto é significativamente reduzido quando comparado ao seu modelo.

Se o *valor-p* para o teste F de teste de significância global for menor que seu nível de significância, você pode rejeitar a hipótese nula e concluir que seu modelo proporciona um ajuste melhor do que o modelo somente com o intercepto.

Avaliação do modelo

Análise dos resíduos (erros)

Os resíduos precisam ser um ruído branco, ou seja, **média zero e variância constante**. Além disso, Devem ser não correlacionados entre si, ou seja, devem ser independentes e devem ter distribuição normal.

1. Análise gráfica
2. Testes Estatísticos:
 - A. Teste de Shapiro-Wilk
H0 é que os resíduos são normais.
 - B. Teste de Durbin-Watson (Verifica se os resíduos são independentes)
H0: Não há correlação entre os resíduos.

Método dos Mínimos Quadrados Ordinários - MQO

Um exemplo:

TABELA 4-1 Resultados de pesquisa sobre uso de cartão de crédito

Identificação da família	Número de cartões de crédito usados (Y)	Tamanho da família (V_1)	Renda familiar (milhares de US\$) (V_2)	Número de automóveis da família (V_3)
1	4	2	14	1
2	6	2	16	2
3	6	4	14	2
4	7	4	17	1
5	8	5	18	3
6	7	5	21	2
7	8	6	17	1
8	10	6	25	2

$$\text{Número de Cartões de crédito} = \alpha + \beta \text{ Tamanho da família}$$

Regressão Linear Simples

Resolvendo no R

exemplo1_cartao_credito

Atividade:

- 1) Utilizando o banco de dados ARVORE, ajuste um modelo de regressão linear simples para prever a altura das árvores em função do diâmetro. Veja essa relação no diagrama de dispersão. Interprete os resultados.
- 2) Utilizando o banco de dados MASSA_MUSCULAR, ajuste um modelo de regressão linear simples para prever a massa em função da idade. Veja essa relação no diagrama de dispersão. Interprete os resultados.